研究综述 · 大语言模型后训练

从 InstructGPT 到推理模型与智能体

——大语言模型后训练方法的技术演进（2022—2026）

2026 年 11 月 · 基于公开技术报告与论文的机制性综述

摘要

后训练已从“让模型听懂指令、符合偏好”的单一对齐阶段，演变为由监督微调、偏好优化、可验证奖励强化学习、多阶段课程与智能体环境交互共同构成的系统工程。本文以 InstructGPT、DeepSeek-V3、DeepSeek-R1、Qwen3、DeepSeek-V3.2、Kimi K2.5 与 GLM-5 的技术报告为主线，辅以 DPO 与 GRPO 的方法论文，梳理 2022—2026 年后训练目标、算法、数据与奖励机制的演进。研究发现：奖励信号正从人工示范与成对偏好，转向规则验证器、可执行环境和生成式奖励；优化对象正从单轮回答转向长程轨迹；训练流程正从单阶段 SFT+RL 转向“冷启动—推理 RL—模式融合—通用/智能体 RL—蒸馏”的多阶段课程；竞争焦点也从算法本身转向环境、奖励与异步 RL 基础设施。本文给出技术演进图与七类方法的比较表，并讨论哪些创新具有普遍意义、哪些依赖特定任务与系统条件。

关键词：后训练；RLHF；DPO；GRPO；RLVR；智能体；多模态

1 引言

2022 年，InstructGPT 用“人工示范 → 奖励模型 → PPO”的三阶段流程，把通用 GPT-3 变成更会听话的助手：1.3B 的 InstructGPT 输出在人类评估中优于 175B GPT-3，175B 版本相对 GPT-3 的胜率为 85%±3%，相对 few-shot GPT-3 为 71%±4%[1]。这确立了 RLHF 的基本范式，也留下了一个昂贵的问题：奖励模型、价值模型、参考模型与在线采样缺一不可。2023 年，DPO 把 KL 约束下的偏好优化改写为离线最大似然，去掉了显式奖励模型和 RL 循环[2]。2024 年底，DeepSeek-V3 用 GRPO、规则/模型奖励与 R1 蒸馏，把“推理数据”纳入后训练[3]；2025 年，DeepSeek-R1 证明纯 RL 可以激发长思维链[4]，Qwen3 把思考与非思考融合进同一个模型[5]；2025 年底，DeepSeek-V3.2 把后训练算力提高到预训练的 10% 以上，并用 1,800 个环境、85,000 条 prompt 做智能体后训练[6]；2026 年，Kimi K2.5 与 GLM-5 又把多模态、并行智能体和异步 RL 推到前台[7][8]。

本文关心四个问题：后训练目标如何变化？算法如何演进？数据与奖励机制如何发展？新一代模型的流程有哪些值得关注的创新？方法上，本文阅读全部指定报告的后训练章节，重点精读 DeepSeek-R1、Qwen3 与 GLM-5，并用 DeepSeek-V3.2、Kimi K2.5 校验智能体与多模态趋势；不做实验复现，而做机制、数据与系统条件的比较。贡献有三：一张 2022—2026 年技术演进图（图 1）、一张七类方法的比较表（表 1），以及一个关于“普遍创新”与“条件依赖”的判断。

2 后训练目标的四次迁移

2.1 2022：指令遵循与偏好对齐

InstructGPT 的目标是让模型“有用、诚实、无害”，并把用户意图作为优化对象。它用约 13k 条示范训练 SFT，用 33k 条成对比较训练 6B 奖励模型，再用 31k 条无标签 prompt 做 PPO；为缓解对齐税，PPO-ptx 还把预训练梯度混入 RL 目标[1]。这一阶段的数据是“人写的答案 + 人对两个答案的偏好”，目标是“让模型像人希望的那样回答”。后训练第一次从“预测下一个词”变成“优化人类评价”。

2.2 2023—2024：偏好优化的效率化

DPO 的关键推导是：KL 约束下最优策略可写成 $\pi^*(y|x) \propto \pi_{ref}(y|x)\exp(r(x,y)/\beta)$，代入 Bradley-Terry 后，配分函数在偏好差中消掉，于是可以直接用偏好对做分类式损失，隐式奖励为 $\hat{r}=\beta \log(\pi_\theta/\pi_{ref})$[2]。这把“奖励模型 + RL 循环”压缩成“单模型 + 参考模型”的离线训练，显著降低了复现门槛。与此同时，DeepSeek-V3 把 R1 生成的长思维链、拒绝采样、规则奖励与 GRPO 结合，说明推理轨迹也可以像偏好数据一样被规模化[3]。后训练的目标从“讨人喜欢”扩展为“既讨人喜欢，又能做对题”。

2.3 2024—2025：可验证推理与测试时扩展

R1-Zero 不用 SFT，只用 GRPO 和两类规则奖励——答案正确、格式合规——就在数学、代码与逻辑任务上让长思维链、自我检查、反思等行为自发出现；R1 再加入几千条冷启动数据、拒绝采样 SFT 与第二轮通用 RL，以修复可读性和语言混杂[4]。Qwen3 用 3,995 个 query-verifier 对做推理 RL，再用 20 多个任务的通用 RL 和强到弱蒸馏，把“思考/非思考”做成同一个模型的可控模式[5]。这一阶段的目标从“人类喜欢”变成“答案可验证、推理可扩展”，奖励从学习出来的偏好模型转向可编程的验证器。

2.4 2025—2026：智能体、多模态与并行

DeepSeek-V3.2 把 thinking 放进 tool-use：只有在新的用户消息到来时才丢弃历史推理，工具结果追加时保留推理，以避免每一轮重复推理；它合成 1,800 个环境、85,000 条 prompt，把搜索、代码、代码解释器和通用 Agent 都纳入 RL[6]。Kimi K2.5 用 zero-vision SFT、视觉结果 RL 和联合多模态 RL，并用并行智能体强化学习（PARL）训练可自主编排 100 个子代理、最多 1,500 次工具调用的 Agent Swarm[7]。GLM-5 用多任务 SFT（交错思考、保留思考、轮级思考）、推理 RL、异步 Agentic RL、通用 RL 与跨阶段在线蒸馏，覆盖 10,000 多个可验证 SWE 环境[8]。目标从“单轮答对”变成“在环境中多轮交付”，后训练的对象也从一条回答变成一条轨迹。

图 1 用“目标—算法—数据/奖励—代表模型”四条泳道概括了这四次迁移。可以看到，目标、算法与数据不是同步线性前进的：DPO 在 2023 年就提供了离线偏好优化，但直到 2025 年，规则验证器和可执行环境成熟后，后训练才真正从“像人”走向“能做对、能交付”。



图 1 2022—2026 年大语言模型后训练技术演进（按“目标—算法—数据/奖励—代表模型”四条泳道排列；方框位置按报告发布时间近似。来源：作者根据文献[1]—[8]整理）

3 算法谱系：从模仿到偏好，再到可验证与轨迹

表 1（文末横排页）给出七类方法的完整比较。这里先沿着“数据—奖励—模型依赖—优化目标”四条线，说明每一种方法解决了什么、又制造了什么新问题。

3.1 SFT：最小可行后训练

SFT 最大化示范轨迹的似然：$L_SFT = -E \log \pi\theta(y|x)$。它只需要 policy 和示范数据，不需要奖励模型、价值模型或参考模型；稳定、便宜，是冷启动和格式注入的默认手段。但 SFT 只能模仿，无法区分“看起来像”与“做对了”，错误轨迹会被放大，能力上限受教师或标注者约束。今天它仍是后训练的第一阶段，却不再是能力上限的来源。

3.2 PPO/RLHF：把偏好变成奖励，再用 RL 优化

InstructGPT 的 PPO-ptx 目标为：$J = E[r_\varphi(x,y) - \beta \log(\pi_\theta(y|x)/\pi_{ref}(y|x))] + \gamma E_{pre} \log \pi_\theta(x)$。其中 r_φ 是奖励模型，β 控制 KL 惩罚，γ 控制预训练回放；PPO 本身还有 clip 和 value loss，价值函数从奖励模型初始化[1]。它需要 policy、奖励模型、价值模型、参考模型四个模型，解决了“只模仿不会优化偏好”的问题，却引入了奖励模型攻击、价值模型昂贵、在线采样方差大、四模型协同复杂等新问题。

3.3 DPO：把 RL 消掉

DPO 直接用偏好对做二分类：$L_{DPO} = -E \log \sigma(\beta \log(\pi_\theta(y_w|x)/\pi_{ref}(y_w|x)) - \beta \log(\pi_\theta(y_l|x)/\pi_{ref}(y_l|x)))$。隐式奖励 $\hat{r}=\beta \log(\pi_\theta/\pi_{ref})$，不需要显式奖励模型，也不需要 PPO 循环，但仍需要参考模型，且数据是离线的[2]。它解决了 PPO 的复杂与不稳定，却带来分布偏移、对偏好数据覆盖敏感、缺少在线探索等新问题；在偏好数据质量高、任务分布稳定的场景，DPO 是性价比最高的选择，但它不会自动获得 RLVR 那样的“越算越对”能力。

3.4 GRPO：去掉 Critic 的组相对优化

GRPO 对每个问题采样 G 个输出，用组内均值与标准差归一化得到优势 $\hat{A}_i$，再套 PPO 式的重要性比率、clip 和 KL：

$$J_{GRPO} = E[\ (1/G)\ \Sigma_i\ (1/|o_i|)\ \Sigma_t \min(r_{i,t}\hat{A}_i,\ clip(r_{i,t},\ 1-\varepsilon,\ 1+\varepsilon)\hat{A}_i) - \beta\ D_{KL}(\pi_\theta \| \pi_{ref})\ ]$$

它保留参考模型（KL 可关掉），但不需要与策略同规模的价值模型；奖励可以来自规则验证器或奖励模型[3][4][9]。与 PPO 相比，GRPO 的显存与工程复杂度更低，适合“一个 prompt 采样一组答案”的推理任务。新问题也很明显：组采样成本高；全对或全错的组方差为零、没有梯度；熵容易塌缩；长度容易膨胀。DeepSeek-V3.2 后续加入无偏 KL、离策略序列 mask、Keep Routing、Keep Sampling Mask，正是为了在放大 batch 和异步 rollout 时稳住这些问题[6]。

3.5 RLVR：把“可验证”变成奖励

RLVR 不是某一个损失函数，而是“GRPO/PPO + 规则验证器”的范式：数学用答案匹配，代码用编译器/单元测试，Agent 用环境状态或测试脚本。R1 明确不对推理任务使用神经奖励模型，因为过程奖励模型（PRM）与结果奖励模型都容易被 reward hacking，且重新训练奖励模型会引入额外算力与复杂度；它只用 accuracy 与 format 两个规则奖励[4]。Qwen3 用 3,995 个 query-verifier 对做推理 RL[5]；V3.2 在推理/Agent 上用规则结果奖励、长度惩罚和语言一致性奖励，通用任务才用生成式奖励模型（GRM）按 rubric 评分[6]。RLVR 解决了“开放域奖励不可靠”的问题，但把瓶颈转移到验证器覆盖、假阴性和任务可验证性上：验证器写不出来的能力，RLVR 就训不出来。

3.6 多阶段与 Agentic/PARL：把能力拼起来

R1 的“冷启动 SFT → 推理 RL → 拒绝采样 SFT → 通用 RL”是第一个被广泛复制的多阶段配方[4]；Qwen3 的“冷启动 → 推理 RL → 思考模式融合 → 通用 RL → 强到弱蒸馏”把模式控制纳入后训练[5]；V3.2 用“专家蒸馏 + 混合 RL”把推理、Agent 与人类对齐合并到一个 RL 阶段，以减少多阶段遗忘[6]；GLM-5 用“SFT → 推理 RL → Agentic RL → 通用 RL → 跨阶段在线蒸馏”，并用异步解耦的 slime 框架支撑长程 rollout[8]。K2.5 的 PARL 则把“编排器”作为可训练策略、子代理冻结，奖励为 $r_{PARL} = \lambda_1 r_{parallel} + \lambda_2 r_{finish} + r_{perf}$，并用 critical steps 约束并行效率[7]。这一阶段的新问题不再是“有没有奖励”，而是“奖励是否可分解、可归因、可扩展”，以及“多阶段之间如何不相互遗忘”。

4 数据与奖励：监督来源的光谱

4.1 从人工示范到环境反馈

表 1 把监督来源排成一条光谱：人工示范（SFT）→ 成对人类偏好（RM/DPO）→ 模型生成 + 拒绝采样（R1/V3/Qwen3）→ 规则验证器（RLVR）→ 可执行环境（SWE/终端/搜索）→ 生成式奖励（GRM）。越往右，规模越大、越可自动扩展，但越依赖任务的可验证性与环境保真度。InstructGPT 的 33k 偏好、R1 的 600k 推理（拒绝采样）+200k 非推理 SFT 数据、V3.2 的 85k prompts/1,800 环境、GLM-5 的 10,000+ SWE 环境，正好标记了这条光谱的四个刻度[1][4][6][8]。

4.2 结果奖励、过程奖励与轨迹奖励

结果奖励只看最终答案，稀疏但抗攻击，适合数学、代码与可自动判定的任务。过程奖励看中间步骤，密集但难定义、难标注、易被攻击：R1 明确报告了 PRM 的三重困难——细粒度步骤难定义、中间步骤对错难判定、模型化 PRM 必然带来 reward hacking——并在实验中放弃它[4]。轨迹奖励看整条多轮交互，除任务成功外还包含工具调用是否合法、子任务是否完成、是否高效、是否安全。K2.5 的 PARL 奖励与 GLM-5 的 Agentic RL 都属于轨迹级：前者用 r_parallel 防止“串行坍缩”、用 r_finish 防止“虚假并行”，后者用可验证环境与 GRM 评估长程任务[7][8]。轨迹奖励最贴近部署，但信用分配也最难：最终失败可能来自编排、子代理、工具或环境中的任何一环。

4.3 合成、拒绝采样与蒸馏

拒绝采样是“用奖励函数当数据过滤器”：R1 用规则验证器筛出约 600k 推理轨迹，Qwen3 用 QwQ-32B 生成候选再过滤，GLM-5 保留错误片段但在损失中 mask，让模型学习纠错而不强化错误动作[4][5][8]。数据合成把“题目 + 验证器”一起生成：V3.2 合成 1,800 个环境/85k prompts，GLM-5 合成 10,000+ SWE 环境与终端任务，K2.5 合成宽搜索/深搜索的并行代理任务[6][7][8]。蒸馏则是“把强模型的能力压缩给弱模型”：V3 蒸馏 R1 的推理数据，Qwen3 用 off-policy + on-policy logit 蒸馏（约 1/10 GPU 时长），GLM-5 用跨阶段在线蒸馏恢复前序能力[3][5][8]。三者的共同点是：把“在线 RL 的昂贵探索”转化为“离线数据 + 过滤 + 教师信号”；风险则是把教师偏差固化，学生模型很难超越教师。

5 新一代模型的流程创新：五个案例

5.1 DeepSeek-R1：纯 RL 的边界与补救

R1-Zero 证明不用 SFT、只用规则奖励也能激发长思维链；但可读性差、语言混杂。R1 用几千条冷启动数据、推理 RL、约 600k 推理（拒绝采样）+ 200k 非推理的 SFT 数据、1,700 步通用 RL 修补[4]。关键创新是“规则奖励 + GRPO + 拒绝采样”的闭环；关键限制是它高度依赖数学、代码等可验证域，通用对话仍要靠奖励模型。R1 也诚实报告了 PRM 与 MCTS 的失败，说明“过程监督”在工程上仍不便宜[4]。

5.2 Qwen3：思考与非思考的融合

Qwen3 的四阶段是“长 CoT 冷启动 → 推理 RL → 思考模式融合 → 通用 RL”，小模型再加“强到弱蒸馏”[5]。最有意义的创新不是某个损失，而是把“是否思考、思考多久”变成模型的可控接口：/think、/no_think、空 think block 和 thinking budget。它解决了“推理模型与聊天模型二选一”的部署问题；代价是通用 RL 会牺牲部分数学/代码峰值（论文自己报告了 AIME/LiveCodeBench 的下降），需要接受“全能 vs 专精”的权衡[5]。

5.3 DeepSeek-V3.2：RL 规模化 + Agent 任务合成

V3.2 把后训练计算提高到预训练的 10% 以上，用 DSA 降低长上下文成本；后训练是“专家蒸馏 + 混合 RL”，六个专家域（数学、编程、逻辑、通用 Agent、Agent 编程、Agent 搜索）各自产出 thinking/non-thinking 数据，再用一个混合 RL 阶段整合[6]。工程上最关键的是四个稳定化技巧：无偏 KL、离策略序列 mask、Keep Routing、Keep Sampling Mask；Agent 上则用 1,800 个环境/85k prompts 合成任务，并让 thinking 在 tool-use 中保留[6]。这说明“RL 规模化”不是简单加卡，而是训练-推理一致性与环境规模的共同放大。

5.4 Kimi K2.5：多模态 + 并行智能体

K2.5 的路线是“原生多模态预训练 → zero-vision SFT → 视觉结果 RL → 联合多模态 RL”，并用 PARL 训练 Agent Swarm：可训练编排器分解任务，冻结子代理并行执行，奖励含并行度、完成率和任务结果，λ 退火到 0；用 critical steps 而非总步数衡量效率[7]。它解决的是“单代理串行在长任务上上下文和工具预算耗尽”的问题；限制是并行只对可分解任务有效，且“虚假并行”需要奖励设计来抑制。K2.5 还提出 Toggle 交替做“预算受限/标准 scaling”，平均降 25—30% token 而性能基本不掉，说明“token 效率”已成为后训练的一等目标[7]。

5.5 GLM-5：异步 RL 与跨阶段蒸馏

GLM-5 的后训练是“多任务 SFT（交错/保留/轮级思考）→ 推理 RL（数学/科学/代码/TIR）→ 异步 Agentic RL（SWE/终端/搜索）→ 通用 RL（正确性/情商/任务能力）→ 跨阶段在线蒸馏”[8]。算法上以 GRPO 为底、用 IcePop 处理训练-推理不匹配、去掉 KL、group/batch 均为 32；Agentic RL 用 TITO、双侧重要性采样、DP-aware 路由、丢弃过旧或环境崩溃样本；基础设施用 slime 解耦生成与训练，支持上千并发 rollout[8]。它展示了“后训练=算法+系统”的极致形态：没有异步基础设施，长程 Agent RL 的 GPU 利用率会被长尾 rollout 吃掉。

5.6 共同趋势与条件依赖

共同趋势有五个：奖励从“人”转向“可验证环境”；流程从单阶段转向多阶段课程；能力从单模型转向“专家/教师/编排器 + 子代理”的组合；训练从同步转向异步解耦；推理从固定转向可控思考与 token 效率。条件依赖也同样明显：R1 的纯 RL 依赖强基座和规则验证器；Qwen3 的融合依赖强推理教师和精细数据配比；V3.2 的 agentic 合成依赖可执行环境与验证器覆盖；K2.5 的 PARL 依赖可分解任务和冻结子代理的稳定接口；GLM-5 的异步 RL 依赖 slime 级别的系统工程。把这些创新直接搬到通用对话或低资源环境，往往会退化为“更贵的 SFT”。

开源实现沿三条线展开：算法库（TRL、OpenRLHF、verl、slime）把 DPO/GRPO/PPO 变成可复用接口；配方复现（Open-R1、SimpleRL-Zoo）验证 R1 式规则 RL 的可迁移性；权重与报告（Qwen3、V3.2、K2.5、GLM-5）公开模型，但通常不公开完整数据、奖励与环境。由此，后训练的复现瓶颈已从“损失函数”转向“数据配比、验证器、环境与异步调度”：这既是开源社区的机会，也是其与闭源系统差距的主要来源。

6 结论

2022—2026 年后训练的主线，是监督信号从“人类示范/偏好”扩展到“可验证结果/环境反馈”，优化对象从“单轮回答”扩展到“长程轨迹”，训练系统从“单阶段 RL”扩展到“多阶段课程 + 异步基础设施”。算法上，SFT 仍是冷启动，PPO 仍是偏好优化的基线，DPO 把偏好对齐变成可复现的离线目标，GRPO/RLVR 让可验证推理规模化，Agentic RL/PARL 把工具、环境和并行编排纳入后训练。真正具有普遍意义的，是“组相对优势 + 规则验证 + 拒绝采样 + 多阶段蒸馏 + 训练-推理一致性”这组可迁移的设计原则；真正依赖特定条件的，是具体环境、奖励函数、并行策略和异步系统。对开源社区而言，算法接口已经高度标准化（TRL、OpenRLHF、verl、slime），下一步的瓶颈在数据、环境和可复现的奖励，而不是又一个损失函数。

局限：本文基于公开报告，未复现实验；各报告的数据配比、算力与评测口径不统一，结论应视为机制性判断而非性能排名。2026 年的模型报告仍缺乏长期独立复现，后续工作需要用统一基准检验这些配方的可迁移性。

参考文献

[1] Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions with human feedback[J]. arXiv:2203.02155, 2022.
[2] Rafailov R, Sharma A, Mitchell E, et al. Direct Preference Optimization: Your Language Model is Secretly a Reward Model[J]. arXiv:2305.18290, 2023.
[3] DeepSeek-AI. DeepSeek-V3 Technical Report[J]. arXiv:2412.19437, 2024.
[4] DeepSeek-AI. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning[J]. arXiv:2501.12948, 2025 (v2, 2026).
[5] Qwen Team. Qwen3 Technical Report[J]. arXiv:2505.09388, 2025.
[6] DeepSeek-AI. DeepSeek-V3.2: Pushing the Frontier of Open Large Language Models[J]. arXiv:2512.02556, 2025.
[7] Kimi Team. Kimi K2.5: Visual Agentic Intelligence[J]. arXiv:2602.02276, 2026.
[8] 智谱 AI. GLM-5 技术报告[R/OL]. 2026-02-21. https://www.zhipuai.cn/zh/research/153.
[9] Shao Z, Wang P, Wang Q, et al. DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models[J]. arXiv:2402.03300, 2024.
[10] Schulman J, Wolski F, Dhariwal P, et al. Proximal Policy Optimization Algorithms[J]. arXiv:1707.06347, 2017.

表 1 后训练代表性方法比较（2022—2026）

从“数据—奖励—模型依赖—优化目标—适用任务—主要局限”六个维度比较 SFT、PPO/RLHF、DPO、GRPO、RLVR、多阶段 RL 与 Agentic/PARL。表中“—”表示不需要，“○”表示可选或视实现而定。

方法（代表）	优化目标 / 损失	数据与反馈	RM / VM / Ref	复杂度与工程	适用任务	主要局限
SFT（InstructGPT，2022）	$L = -E \log \pi\theta(y\|x)$ 逐 token 最大似然；无奖励项	人工示范或教师轨迹；无偏好、无环境反馈	RM — VM — Ref —	低。单模型离线训练，epoch 视数据而定	指令遵循、格式、冷启动、蒸馏落地	模仿上限；分布偏移；错误轨迹被放大；无法优化最终结果
PPO / RLHF（InstructGPT，2022）	$\max E[r\varphi(x,y) - \beta \log(\pi\theta/\pi ref)] + \gamma E_pre \log \pi\theta(x)$ PPO clip + value loss；逐 token KL	prompt + 成对偏好；在线 rollout；RM 打分	RM ✓ VM ✓ Ref ✓	很高。策略、RM、价值、参考四模型；在线采样与调参	开放式对话、有用性/安全性、风格对齐	RM 奖励攻击；价值模型昂贵；PPO 方差大；四模型协同复杂
DPO（2023）	$L = -E \log \sigma(\beta \log[\pi\theta(yw)/\pi ref(yw)] - \beta \log[\pi\theta(yl)/\pi ref(yl)])$	离线成对偏好；无需在线采样；可用公开偏好数据	RM — VM — Ref ✓	低—中。单可训练模型 + 参考；无 RL 循环	偏好对齐、风格、安全、低成本复现	离线分布偏移；对数据覆盖敏感；缺少探索；可能放大表面特征
GRPO（2024—2025）	组内归一化 $\hat{A}_i$；clip 重要性比率 + KL；无 critic	每个 prompt 采样 G 个输出；规则验证器或 RM 打分	RM/Verifier ✓ VM — Ref ○	中—高。group rollout；显存友好；需处理零方差组	数学、代码、STEM 推理；可验证任务	组采样贵；全对/全错无梯度；熵塌缩；长度膨胀
RLVR（R1/Qwen3/V3.2）	GRPO/PPO + 二元规则奖励 $r \in \{0,1\}$；可加格式、语言、长度奖励	query–verifier 对；答案匹配、编译器、单元测试、环境状态	Verifier ✓ RM — Ref ○	中—高。验证器与 rollout 是瓶颈；需防假阴性	可验证推理、代码、部分 Agent 任务	覆盖域窄；奖励稀疏；假阴性；基准过拟合；难用于开放域
多阶段 RL（R1/Qwen3/V3.2/GLM-5）	冷启动→推理 RL→模式融合→通用 RL→蒸馏；顺序优化多个目标	SFT + verifier + 偏好 + 环境混合；阶段配比关键	Verifier/RM ✓ VM — Ref ○	高。阶段课程、遗忘控制、蒸馏；比单阶段更复杂	推理+通用+Agent 的统一模型	阶段干扰；灾难性遗忘；配比敏感；工程复杂
Agentic / PARL（GLM-5/K2.5）	多轮任务回报 + 轨迹/辅助奖励；PARL 另加并行度与完成率	可执行环境、长程轨迹、GRM、并行任务	Env/Verifier ✓ RM/GRM ○ Ref ○	极高。异步 RL、环境编排、子代理调度	SWE、搜索、终端、多模态、并行代理	延迟/稀疏/非平稳奖励；信用分配；虚假并行；模拟到现实

注：RM=奖励模型，VM=价值/评论家模型，Ref=参考模型；✓ 必需，○ 可选或视实现，— 不需要。SFT 与 DPO 为离线目标，PPO、GRPO、RLVR、多阶段 RL 与 Agentic/PARL 为在线或半在线目标。来源：作者根据文献[1]—[10]及表内模型报告整理。